

= Mezclas de Normales en media-varianza =

x - vector p -dimensional ($x = (x_1, \dots, x_p)'$)

μ - vector p -dimensional ($\mu = (\mu_1, \dots, \mu_p)'$)

γ - vector p -dimensional ($\gamma = (\gamma_1, \dots, \gamma_p)'$)

Σ - matriz de covarianzas ($p \times p$).

λ - escalar positivo.

©1

P: David Castillo

$\lambda \mapsto \mu + \lambda \gamma$ es un mapeo de \mathbb{R}_+ a \mathbb{R}^p
 en un vector de localización μ y una dirección
 dada por el vector γ , en magnitud λ .

$\lambda \mapsto \lambda \Sigma$ es un mapeo de \mathbb{R}_+ a $\mathbb{R}^{p \times p}$ (simétricas)
 es una expansión (o contracción, pues $\lambda < 1$) de Σ .
 en todas direcciones.

Modelo Parte 1

$$X | \lambda, \mu, \gamma, \Sigma \sim N_p(x | \mu + \lambda \gamma, \underbrace{\lambda \Sigma}_{\text{varianza}})$$

$$f(x | \lambda, \mu, \gamma, \Sigma) = |\Sigma|^{-1/2} \lambda^{-p/2} \exp \{ (x - \mu)' \Sigma^{-1} \gamma \} \\
\times \exp \left\{ -\frac{1}{2\lambda} (x - \mu)' \Sigma^{-1} (x - \mu) \right\} \\
\times \exp \left\{ \frac{1}{2/\lambda} \gamma' \Sigma^{-1} \gamma \right\}.$$

supongamos que $\lambda \sim g(\cdot)$

$$\Rightarrow p(x | \mu, \gamma, \Sigma) = \underbrace{\int_{\mathbb{R}_+} N_p(x | \mu + \lambda \gamma, \lambda \Sigma) \cdot g(\lambda) d\lambda}_{\text{mezcla en media-varianza}}$$

Caso particular.

Si $\lambda \sim \text{Generalized-Inverse-Gaussian}$

$\Rightarrow p(x|\mu, \gamma, \Sigma) \leftarrow \text{Distribución hipobólica generalizada.}$
(McNeil, pp. 78-85)

Caso alternativo

$\lambda \sim \text{Gaussiana-Inversa (inverse-gaussian)}$

Ambos casos, $p(x|\mu, \gamma, \Sigma)$ tiene curvas de nivel ^{no} elípticas. Las distribuciones marginales asimétricas, por los argumentos de x .

Identificabilidad (p. 79, McNeil)

los puntos Σ y γ inducen la misma distribución que $k\Sigma$ y $k\gamma$ para todo $k > 0$.

\Rightarrow restringir $|\Sigma| \leftarrow$ determinante, sea de un valor particular. Particularmente $|\Sigma| = 1$, a partir de la matriz de correlaciones.

Modelo Parte I

$$p(x|\mu, \gamma, \Sigma) = \int_{\mathbb{R}_+} N_p(x|\mu + \lambda\gamma, \lambda\Sigma) \text{Ga-inv}(\lambda) d\lambda$$

con $\text{Ga-inv}(\lambda) \leftarrow \text{Gaussiana-Inversa}$, en función de densidad:

$$f(x|\lambda|\alpha, \beta) = \left(\frac{\beta}{2\pi\lambda^3}\right)^{1/2} \exp\left\{-\frac{\beta(\lambda-\alpha)^2}{2\alpha^2\lambda}\right\} \mathbb{1}_{(0, \infty)}(\lambda)$$

con $\alpha > 0 \leftarrow$ parámetro de localización
 $\beta > 0 \leftarrow$ parámetro de escala

$$\mathbb{E}(\lambda|\alpha, \beta) = \alpha$$

$$\text{var}(\lambda|\alpha, \beta) = \frac{\alpha^3}{\beta}$$

Modelo Parte 1

03

Parámetros:

- 1) μ - vector ($p \times 1$) $\in \mathbb{R}^p$
- 2) γ - vector ($p \times 1$) $\in \mathbb{R}^p$
- 3) Σ - matriz ($p \times p$) \leftarrow correlación con $|\Sigma| = 1 \in \mathbb{R}^{p \times p}$.
- 4) α - media (localización) $\in \mathbb{R}_+$
- 5) β - parámetro $\in \mathbb{R}_+$.

Modelo jerárquico

~~\mathbb{R}^p~~ $x_j | \lambda_j, \mu, \gamma, \Sigma, \alpha, \beta \sim \mathcal{N}$

I. — $x_j | \lambda_j, \mu, \gamma, \Sigma, \alpha, \beta \stackrel{\text{ind}}{\sim} \mathcal{N}_p(x_j | \mu + \lambda_j \gamma, \lambda_j \Sigma) \quad (\text{observable})$
 $j = 1, \dots, n$

$\lambda_j \stackrel{\text{ind}}{\sim} \text{GaussInv}(\lambda_j | \alpha, \beta) \quad (\text{latente})$

II. — distrib. iniciales sobre parámetros.

sobre obs. — $\pi(\mu, \gamma, \Sigma)$

sobre latentes — (α, β)

$$\pi(\underbrace{\mu, \gamma, \Sigma}_{\text{o/obs}}, \underbrace{\alpha, \beta}_{\text{o/lat.}}) =$$

$$= \pi(\mu, \gamma, \Sigma) \cdot \pi(\alpha, \beta)$$

$$= \pi(\mu | \Sigma) \cdot \pi(\gamma | \Sigma) \cdot \pi(\Sigma) \cdot \pi(\alpha) \cdot \pi(\beta).$$

Sobre ~~os~~ hiperparâmetros:

(0.1)

$$\pi(\alpha) = \text{Gamma}(\alpha | a_\alpha, b_\alpha)$$

$$\pi(\beta) = \text{Gamma}(\beta | a_\beta, b_\beta).$$

$$a_\alpha, b_\alpha > 0$$

$$a_\beta, b_\beta > 0$$

Hiperparâmetros

Sobre observáveis:

$$\pi(\mu | \Sigma) = N_p(\mu | m_\mu, s_0 \Sigma)$$

$$\pi(\gamma | \Sigma) = N_p(\gamma | m_\gamma, s_0 \Sigma)$$

$$m_\mu, s_0$$

$$m_\gamma, s_0$$

Hiperparâmetros

$$\pi(\Sigma) = \text{Wishart}(\Sigma | \nu, S)$$

$$\nu > p \leftarrow \text{graus de liberdade}$$

$$S \in \mathbb{R}^{p \times p} \text{ positivo definido}$$

Hiperparâmetros.

Verossimilhança:

$$p(\underbrace{x_1, \dots, x_n}_{\text{obs}} | \mu, \gamma, \Sigma, \alpha, \beta) =$$

$$= \prod_{j=1}^n p(x_j | \mu, \gamma, \Sigma, \alpha, \beta)$$

$$= \prod_{j=1}^n \int_{\mathbb{R}_+} N_p(x_j | \mu + \lambda \gamma, \lambda \Sigma) \cdot G \cdot \ln(\lambda | \alpha, \beta) d\lambda$$

Verossimilhança estendida:

$$p(\underbrace{x_1, \dots, x_n}_{\text{obs}}, \underbrace{\lambda_1, \dots, \lambda_n}_{\text{latentes}} | \mu, \gamma, \Sigma, \alpha, \beta) =$$

$$= \prod_{j=1}^n N_p(x_j | \mu + \lambda_j \gamma, \lambda_j \Sigma) \cdot G \cdot \ln(\lambda_j | \alpha, \beta)$$

Teo Bayes

(05)

Distribución final sobre ~~mu~~ los latentes, y parámetros,

$$\pi(\mu, \gamma, \Sigma, \alpha, \beta, \lambda_1, \dots, \lambda_n | x_1, \dots, x_n) =$$

$$= \left\{ \prod_{j=1}^n N_p(x_j | \mu + \lambda_j \gamma, \lambda_j \Sigma) \cdot \text{Gau-Lnr}(\lambda_j | \alpha, \beta) \right\}$$

$$\times G_0(\alpha | a_\alpha, b_\alpha) \cdot G_0(\beta | a_\beta, b_\beta)$$

$$\times N_p(\mu | m_\mu, s_0 \Sigma)$$

$$\times N_p(\gamma | m_\gamma, s_0 \Sigma)$$

$$\times w_i(\Sigma | \tau, s_0)$$

— — — — — (*)

Hipótesis parámetros:

•) $a_\alpha, b_\alpha > 0$

••) $a_\beta, b_\beta > 0$

•••) m_μ y m_γ , ambos $\in \mathbb{R}^p$

••••) $s_0 > 0$

—) $\tau > 0$

—) $S \in \mathbb{R}^{p \times p}$ positivo definido y simétrica.

Fijados /
calibrados
por nosotros.

(*) no tiene solución analítica.

➡ Necesitamos emplear el Gibbs sampler (entre otros).

= Algoritmo - Gibbs sampler =

(06)

Parámetros del algoritmo:

$M \leftarrow$ extensión de la cadena de Markov (# simulaciones)

Fijar repositorios para

α ~~ap, b, a~~ \leftarrow vector $M \times 1$

β ~~ap, b, a~~ \leftarrow ✓ ✓

μ, γ \leftarrow arreglo de $M \times p$.

Σ \leftarrow arreglo de $M \times p \times p$.

λ_j 's \leftarrow arreglo de $M \times n$

Fijar hiperparámetros:

$a_\alpha, b_\alpha \leftarrow$ dos escalares positivos

$a_\beta, b_\beta \leftarrow$ ✓ — positivo

$m_\mu, m_\gamma \leftarrow$ dos vectores de $p \times 1$

$\tau \leftarrow$ un escalar positivo

$S_0 \leftarrow$ ✓ — —

$S \leftarrow$ matriz $(p \times p)$ positivo definido y métrica.

Fijar valores iniciales

$\alpha^{(0)}, \beta^{(0)}, \mu^{(0)}, \Sigma^{(0)}, \gamma^{(0)}$

} parámetros

$\lambda_1^{(0)}, \dots, \lambda_n^{(0)}$

} latentes.

Recursión:

para $m=1, \dots, M$

a) $\alpha^{(m)} | \dots \sim \pi(\alpha | \dots) \propto$

$\propto \prod_{j=1}^n \text{Ga-Inv}(\lambda_j^{(m-1)} | \alpha, \beta^{(m-1)})$

$\cdot \text{Ga}(\alpha | a_\alpha, b_\alpha).$

b) ~~para~~

$$\beta^{(m)} | \dots \sim \pi(\beta | \dots) \\ \propto \prod_{j=1}^n \text{Geo-Inv}(\lambda_j^{(m-1)} | \alpha^{(m)}, \beta) \cdot \text{Geo}(\beta | a_\beta, b_\beta).$$

$$c) \mu^{(m)} | \dots \sim \pi(\mu | \dots)$$

$$\propto \prod_{j=1}^n N_p(x_j | \mu + \lambda_j^{(m-1)} \gamma^{(m-1)}, \lambda_j^{(m-1)} \Sigma^{(m-1)}) \\ \cdot N_p(\mu | m\mu, s_0 \Sigma^{(m-1)}) \\ \propto \prod_{j=1}^n N_p(x_j - \lambda_j^{(m-1)} \gamma^{(m-1)} | \mu, \lambda_j^{(m-1)} \Sigma^{(m-1)}) \\ \cdot N_p(\mu | m\mu, s_0 \Sigma^{(m-1)})$$

$$d) \gamma^{(m)} | \dots \sim \pi(\gamma | \dots)$$

$$\propto \prod_{j=1}^n N_p(x_j | \mu + \lambda_j^{(m-1)} \gamma^{(m-1)}, \lambda_j^{(m-1)} \Sigma^{(m-1)}) \\ \cdot N_p(\gamma | m\gamma, s_0 \Sigma^{(m-1)}) \\ \propto \prod_{j=1}^n N_p\left(\frac{x_j - \mu^{(m)}}{\lambda_j^{(m-1)}} | \gamma, \Sigma^{(m-1)}\right) \\ \cdot N_p(\gamma | m\gamma, s_0 \Sigma^{(m-1)})$$

$$e) \Sigma^{(m)} | \dots \sim \pi(\Sigma | \dots)$$

$$\propto \prod_{j=1}^n N_p(x_j | \mu^{(m)} + \lambda_j^{(m-1)} \gamma^{(m)}, \lambda_j^{(m-1)} \Sigma) \\ \cdot w_i(\Sigma | z, s)$$

$$\propto \prod_{j=1}^n N_p \left(x_j / \lambda_j^{(m-1)/2} \mid \frac{\mu^{(m)} + \lambda_j^{(m-1)} \gamma^{(m)}}{\lambda_j^{(m-1)/2}}, \Sigma \right) \quad (08)$$

• $w_i(z \mid r, s)$

f) $\pi(\lambda_1, \dots, \lambda_n \mid \dots) \propto$ (no se puede calcular analíticamente; empleamos un pr.)

para $j=1, \dots, n$

$$\lambda_j^{(m)} \mid \dots \propto \text{Geo-Inv}(\lambda_j \mid \alpha^{(m)}, \beta^{(m)})$$

• $N_p(x_j \mid \mu^{(m)} + \lambda_j \gamma^{(m)}, \lambda_j \Sigma)$

Final (Salida)

En cada iteración m ($m=1, \dots, M$)

almacenamos

- $\alpha^{(m)}$
- $\beta^{(m)}$
- $\mu^{(m)}$
- $\gamma^{(m)}$
- $\Sigma^{(m)}$
- $\lambda_1^{(m)}, \dots, \lambda_n^{(m)}$

en los repositorios correspondientes. . .